



T.C.
İSTANBUL MEDENİYET ÜNİVERSİTESİ
MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ

MEZUNİYET ÇALIŞMASI

DERİN ÖĞRENME ile FOTOĞRAFLARDAN YAŞ
TAHMİNİ

Büşra KOÇYİĞİT-18120808016

MATEMATİK BÖLÜMÜ

Danışman

Dr.Öğr.Üyesi Betül HİÇDURMAZ

HAZİRAN, 2022
İSTANBUL

ÖNSÖZ

Bu çalışma İstanbul Medeniyet Üniversitesi, Mühendislik ve Doğa Bilimleri Fakültesi, Matematik Bölümü, Mezuniyet Projesi için yapılmış bir çalışmadır.

Bu çalışmada denetimli yaş aralığı tahmini yapılarak bireylerin yaşlarını tahmin etmek hedeflenmiştir. Hali hazırda var olan, önceden eğitilmiş modeller yorumlanarak ve geliştirilerek yaş tahmini algoritması elde edilmiştir. Bir grup bireyin fotoğraflarından oluşan veri seti üzerinde oluşturulan model tahmini için kullanılmıştır. Modeli eğitmek için WIKI veri seti kullanılmıştır.

Ayrıca henüz tazeliğini koruyan DeepFace hazır paketinin 'yüz öznitelik analizi' kullanılarak yaş tahmini yapılmıştır.

Çalışmada kullanılan tüm kodlar Github deposuna yüklenmiştir.

İçindekiler

ÖNSÖZ	i
1 GİRİŞ	1
2 Yüz Tanıma	2
3 Yüz Dedektörü	2
4 Veri	3
4.1 Veri Özellikleri	3
4.2 Veri Ön İşleme	4
4.3 Bölme Stratejisi	5
5 Yöntem	5
5.1 CNN Mimarisi	5
5.1.1 Optimize Ediciler	7
5.1.2 Çalışma Ortamları ve Kütüphaneler	7
5.2 Sonuç	8
5.3 Hata Yüzdesi	9
6 DeepFace	11
6.1 Deepface Nedir?	11
6.2 DeepFace Nasıl Kullanılır?	11
6.3 DeepFace Yüz Tanıma Modelleri	11
6.4 DeepFace'da Yüz Tanıma Analizi Nasıl Yapılır?	12
6.4.1 Yüz Doğrulama	12
6.4.2 Yüz Tanıma	12
6.4.3 Yüz Öznitelik Analizi	13
6.4.4 Gerçek Zamanlı Yüz Analizi	13
6.5 Yüz Dedektörleri:	13
6.6 Yüz Öznitelik Analizi	14
6.7 Sonuç	15
6.8 Hata Yüzdesi	15
6.9 Yorum	15

1 GİRİŞ

Bir kişinin kimliği, yaşı, cinsiyeti, duyguları ve etnik kökeni, yüzlerindeki özellikler tarafından belirlenir. Güvenlik ve video gözetimi, elektronik müşteri ilişkileri yönetimi, biyometri, elektronik satış makineleri, insan-bilgisayar arayüzü, eğlence, kozmetoloji ve adli tıp, yaş ve cinsiyet sınıflandırmasının kullanışlı olabileceği gerçek dünya uygulamalarından sadece birkaçıdır.

Bu çalışmanın amacı denetimli yaş aralığı tahmini yapılarak bireylerin yaşlarını tahmin etmektir. Görüntülerden yaş tahmini ile ilgili mevcut araştırmalar, tahminlerin nasıl yapıldığına bağlı olarak iki yöntemle yapılabildiğini göstermektedir. Problem yaşların yaş kutularına dönüştürüldüğü çok sınıflı bir sınıflandırma problemi olarak ya da kesin yaşın tahmin edildiği bir regresyon problemi olarak ele alınabilmektedir. Bu çalışmada sınıflandırma yöntemi ile çalışılmıştır. İncelemeler sonucunda daha önceden bu konuda yapılan çalışmalarda CNN (Evrişimsel Sinir Ağı) modelinde ve VGG-16 (Basit bir ağ modeli olup öncesindeki modellerden en önemli farkı evrişim katmalarının ikili veya üçlü kullanılmasıdır. Girişten çıkışa doğru matrislerin yükseklik ve genişlik boyutları azalırken derinlik değeri artmaktadır.) modelinin ince detaylandırmaları ile sonuca ulaşıldığı gözlemlenmiştir. Bu çalışma modeli CNN modeli ile sonuçlandırmıştır. Bu çalışmada kaynak olarak Facial Demographics [8] kullanılmıştır.

Fotoğraftan yaş tahmini yapılırken ikinci bir yöntem olarak yeni bir kütüphane olan DeepFace kütüphanesi özellikleri kullanıldı. 7 yıllık bir kütüphane olan DeepFace yeni bir kütüphane olmasına rağmen gayet olumlu sonuçlar verebilmektedir. Yaratıcıları arasında Türk bir yazarın da bulunduğu bu pakette çalışılırken Şefik İlkin Serengil'in çalışmalarından yardım alındı. DeepFace kütüphanesine ait olan yüz öznitelik analizinin *analyze()* fonksiyonu ile yaş tahmini yapıldı. (*analyze()* fonksiyonu ile yaş, cinsiyet, duygu ve etnik köken tahmini yapılmaktadır. Fakat biz yaş tahminini göz önünde tutup diğer çıktıları göz ardı ettik.) Cihazda bulunan herhangi bir fotoğraf sisteme tanıtıldı ve çalıştırıldı.

Oluşturulan CNN ve DeepFace paketi, oluşturulan özgün test seti üzerinde hata analizine tabii tutuldu.

Çalışmanın genel kapsamı şu şekildedir:

İkinci kısım yüz tanımanın temellerinden bahseder. Üçüncü kısım modeller oluşturulurken faydalanan yüz dedektörünü açıklar. Dördüncü kısım verinin ön işlemlerini anlatır. Beşinci kısım referans olarak kullanılan [8] çalışmasından faydalanan oluşturulan CNN modelini açıklar ve özgün veri seti üzerinde test edilir. Altıncı kısımda benzer uygulama DeepFace kütüphanesi kullanılarak yapılır.

2 Yüz Tanıma

Yüz tanıma, bir kişinin yüzünü kullanarak kimliğini tanımlamanın veya doğrulamanın bir yolu olarak tanımlanır. Yüz tanıma sistemleri, kişileri fotoğraflarda, videolarda ya da gerçek zamanlı olarak tanımlamak için kullanılmaktadır. Yüz tanıma, biyometrik güvenliğin bir kategorisidir.

Yüz tanıma; telefonların kilidini açma, hukuki uygulamalar, havaalanları ve sınır denetimi, kayıp kişilerin bulunması, hırsızlık, bankacılık, pazarlama ve reklam, sağlık, öğrenci ve çalışan devamsızlığını izleme, sürücülerini tanıma vb. gibi bir çok alanlarda kullanılmaktadır. Yüz tanıma teknolojisinin güvenlik, düşük suç oranı, kolaylık, hız gibi çeşitli avantajları varken gözetim, hata ihtimali, gizlilik ihlali, büyük veri depoları gibi riskleri de mevcuttur. Yüz tanıma yapılırken aşağıdaki aşamalar izlenir:


1. adım: Yüz algılama
2. adım: Yüz analizi
3. adım: Görüntüyü veriye çevirme
4. adım: Eşleştirme

Bu çalışmada eşleştirme aşaması yerine, veriye çevrilen görüntüyü kullanarak yaş tahmini yapıldı.

3 Yüz Dedektörü

Yüz dedektörü, görüntüdeki yüzün sınırlayıcı kutu koordinatlarını üretir. Yüzün sınırlayıcı kutusu (x, y) -koordinatları göz önüne alındığında, görüntünün/çerçevenin geri kalanını yok sayarak önce yüz ROI'si çıkarılır. Bu işlem sonucunda görüntüdeki amaç dışı görüntüler yok sayılır ve yalnızca kişinin yüzüne odaklama sağlanır.

Projenin amacı insanın yaşını tahmin etmek olduğundan bu tahmin ancak yüze bakılarak yapılabilir. Tahmin için yüzün ilgili bölgesinin alınması doğruluğu yüksek oranda arttırmaktadır. Bununla birlikte eğitim verisinin boyutunu işlemleri hızlandırmada faydalı olacak şekilde düşürmektedir.



Şekil 1: Yüz Dedektörü

4 Veri

Modeli eğitmek ve sonuçları üretmek için kullanılan veriler, tümü yalnızca yaşlarına göre etiketlenmiş kişilerin görüntülerini içeren DEX: Deep EXpectation of apparent age from a single image çalışmasında da kullanılan WIKI veri setidir. [6]



Şekil 2: Veri setinden Bazı Örnek Görüntüler
Kaynak: DEX

4.1 Veri Özellikleri

WIKI veri seti yaklaşık 63.000 veriden oluşmaktadır. Ancak çalışmada bunların yaklaşık 34.000'lik kısmı kullanılmıştır. Bu durumun iki nedeni vardır. İlki daha genç yaş gruplarının toplu veri kümesinde daha iyi bir temsil verdiği gözlemlenmiştir. Bu yüzden ortalama yaş küçültülmüş, doğmamış resimler, algılanamayan yüzler veriden atılmıştır. İkincisi veri setindeki görüntülerin çoğu makyajlı ve mükemmel aydınlatma koşullarında fotoğraflanmış

aktörleri içermektedir, bu da verileri normal popülasyon için daha az temsili hale getirmekte idi ve bu sebeplerden ötürü veri küçültülmeye gidilmiştir.

WIKI görüntüleri için, tüm meta bilgileri içeren Matlab ile yüklenebilen ayrı bir .mat dosyası mevcuttur. Biçim aşağıdaki şekildedir;

dob: Doğum tarihi (Matlab seri tarih numarası)

photo taken: Fotoğrafın çekildiği yıl

full path: dosya yolu

gender: Kadın için 0 ve erkek için 1, bilinmiyorsa NaN

name: Ünlünün adı

face location: Yüzün konumu. Matlab çalışmasında yüzü kırpma için yardımcıdır.

face score: Dedektör puanı (ne kadar yüksekse o kadar iyidir). Inf , görüntüde hiçbir yüz bulunmadığını ve daha sonra face location ögesinin görüntünün tamamını döndürdüğünü ima eder.

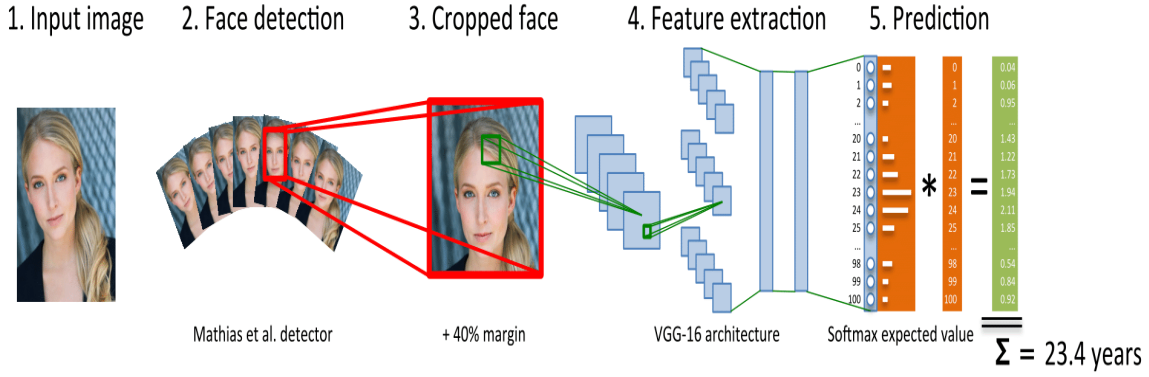
second face score: ikinci en yüksek puana sahip yüzün dedektör puanı. Bu, birden fazla yüzü olan görüntüleri yok saymak için kullanışlıdır. Second face score, ikinci bir yüz algılanmadıysa NaN'dir.

Bir kişinin yaşı fotoğrafın çekildiği yıldan doğduğu yıl kadar eksiği olduğundan;
 $age = photo\ taken - dob$ şeklinde tanımlandı.

4.2 Veri Ön İşleme

Veri setinde; verilerde mesafe, aydınlatma, açılar ve çözünürlüklerde bazı farklılıklar bulunmaktadır. Görüntüler arasındaki farklılıklar, modelin kalıpları bulmasını ve öğrenmesini zorlaştırır. Bu nedenle, model eğitilmeden önce verilerin ön işleme ihtiyacı vardır. Ön işleme aşamaları aşağıdaki gibidir:

1. Aşama: Yüz Tespiti
2. Aşama: Kırpma ve Yeniden Şekillendirme
3. Aşama: Görüntüleri Kutulara Bölme İşlemi
4. Aşama: Temizleme
5. Aşama: Veri Geliştirme



Şekil 3: Yaş Tahmini için Modelin Ardışık Düzeni
Kaynak: DEX

4.3 Bölme Stratejisi

Eğitim sırasında, işlenen veri kümesi karıştırıldı ve bir eğitim kümesine (%70) ve bir doğrulama kümesine (%30) bölündü. Test edilen modellerin her biri eğitim setinde sıfırdan eğitildi ve validasyon setinde valide edildi. Nihai model mimarisi ve hiperparametreler bulunduğundan sonra, eğitim verisi ile model eğitildi ve doğrulama verisi üzerindeki hata belirlendi. Modelin sonuçları ilerideki bölümlerde daha ayrıntılı olarak açıklanmıştır.

5 Yöntem

Yaş tahmini problemini çözmek için bir evrimsel sinir ağı (CNN) kullanılmıştır.

5.1 CNN Mimarisi

CNN (Evrimsel Sinir Ağı) görüntü işlemede kullanılan ve girdi olarak görselleri alan bir derin öğrenme algoritmasıdır. Farklı işlemlerle görsellerdeki özellikleri yakalayan ve onları sınıflandıran bu algoritma çeşitli katmanlardan oluşmaktadır. Convolutional Layer, Pooling ve Fully Connected olan bu katmanlardan geçen görsel, farklı işlemlere tabii tutularak derin öğrenme modeline girecek duruma gelir.

Evrimsel sinir ağları yapısı gereği input olarak resim veya video alır. Resimleri alırken ilgili formata çevrilmiş olması gerekir. Bir konvolüsyonel sinir ağına bir resim verilirse matris formatında verilmelidir. Kısaca bu çalışmada fotoğraf olan girdi öncelikle matris formatına

çevrilmiştir. Konvolüsyon (Convolution) işleminden sonra pooling (birleştirme) işlemi yapılır.

Pooling; görüntünün özelliklerini kaybetmeden daha küçük boyutta bir matris elde edilmesini amaçlar. Pooling işlemi sonucunda her bir görüntü için bir matrise ulaşılır.

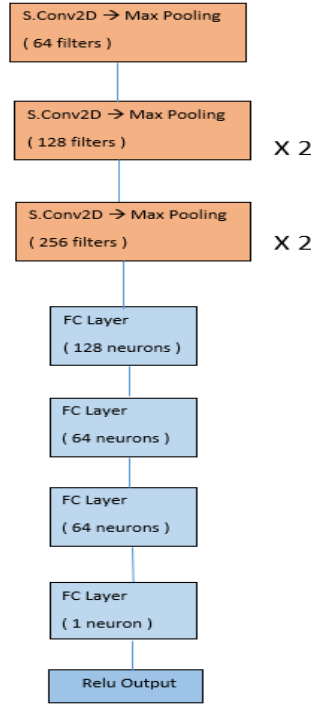
Diğer bir işlem ise Relu işlemidir. Modelde çalışırken negatif değerler ile çalışılmak istenmez. Relu ile negatif değerler 0 kabul edilip ortadan kaldırmış olunur. Bu şekilde bir matris konvolüsyona verildiğinde konvolüsyonun çıktısı reluya input olarak girecektir. Ordan çıktıktan sonra ise pooling'e input olarak girecektir. Daha sonra Fully Connected sinir ağı ile bağlantı sağlanıp ve buradan artık bir skarlama işlemi gerçekleştirilecektir.

Bu çalışmada CNN modelini kullanmamızın 3 nedeni vardır:

İlk olarak, görüntü verilerinden verimli bir şekilde öğrenebilen bir model oluşturmak için, modelin yakın mesafedeki piksellerin büyük olasılıkla ilişkili olduğunu anlaması önemlidir. Görüntü verileri üzerinde geleneksel çok katmanlı algılayıcılar (MLP'ler) kullanıldığında, görüntüler tek boyutlu vektörlere düzleştirildiğinde ve MLP'ye beslendiğinde verilerin uzamsal yapısı kaldırıldığından bu ilişkiler kaybolur. Buna karşılık, CNN'ler doğrudan iki boyutlu görüntüler üzerinde çalışabilir ve verilerdeki uzamsal yapının korunmasına izin verir.

İkincisi, geleneksel FC ağlarının aksine, bir CNN parametre paylaşımını gerçekleştirir ve seyrek bağlantıya sahiptir, yani kayan nokta işlemlerinin sayısı ve bellek gereksinimleri önemli ölçüde azalır. Böylece ağırlık hesaplamaya kaynakları üzerinde daha büyük miktarlarda veri üzerinde çalışmasına izin verir. Seyrek bağlı olmalarına rağmen, CNN'lerin alıcı alanı derinlikle artar ve daha derin katmanlardaki bir birimin dolaylı olarak girdi alanının çoğuna veya hatta tümüne bağlanmasına izin verir.

Üçüncüsü, havuzlama katmanları nedeniyle, CNN'ler, yüz görüntüleri ile uğraşırken çok önemli olan çeviri değişmezliği, yani görüntüdeki hedeflerin konumsal kaymaları ile başa çıkma yeteneğine sahiptir. Modelin genelleme yeteneğini arttırmak için veriler havuzlamaya tabii tutuldu. CNN'lerin havuzlama katmanları, modeli bu yapay büyütmelemlerin yanı sıra gerçek görüntülerde meydana gelen öteleme değişmezleri için de değişmez kılmaktalar.



Şekil 4: Yaş tahmini için model mimarisi
Kaynak: Facial Demographics

5.1.1 Optimize Ediciler

Optimizasyon algoritmaları, optimum ağırlıkları bulmayı, hatayı en aza indirmeyi ve doğruluğu en üst düzeye çıkarmayı amaçlamaktadırlar.

Adam, Derin Öğrenmenin süper yıldız optimizasyon algoritması olarak tanımlanmaktadır. Adam modelinde her ağırlığa göre toplam hatanın kısmi türevi bulunup bu hesaplama ağırlıkları güncellemek için kullanılır.

$$w_i = w_i - \alpha \left(\frac{\partial Error}{\partial w_i} \right)$$

Bu projede Adam Modeli kullanılmıştır.

5.1.2 Çalışma Ortamları ve Kütüphaneler

Proje Python dilinde, yazılmıştır. Çeşitli py ortamlarında denenmiş, hata almadan çalıştırılmıştır. (Jupyter Notebook, Spyder, Pycharm, Google Colab) Projenin kodları Github'da

bulunmaktadır. .ipynb formatında yer alan kodlar indirildikten sonra aşağıda yer alan kütüphaneler tanımlandıktan sonra proje çalıştırılabilir duruma gelmektedir.

numpy: Numpy, bir matematik kütüphanesi olarak tanımlanabilmektedir. Çok boyutlu dizilerle ve matrislerle çalışılan bu kütüphane veri bilimciler tarafından fazlasıyla tercih edilmektedir.

pip install numpy ile cihaza indirilip import numpy as np ile kütüphane tanımlandıktan sonra artık kütüphane kullanılabilir hale gelir.

pandas: Pandas, kullanılan veriyi analize uygun hale getirmek için kullanılan bir kütüphanedir. Veri bilimi projelerinde veri okunması, görselleştirilmesi, ön işleme ve temizlik aşamaları gibi işlemler bu kütüphane sayesinde daha kolay hale gelir.

pip install pandas ile cihaza indirilip import pandas as pd ile kütüphane tanımlandıktan sonra artık kütüphane kullanılabilir hale gelir.

tensorflow: Tensorflow, derin öğrenme için ücretsiz ve açık kaynaklı bir kütüphanedir. Yapay sinir ağlarının eğitimi ile çalışmaktadır. Veri akışına ve türevlenebilir programlamaya dayalı sembolik bir matematik kitaplığı olarak tanımlanmaktadır. Tensorflow bütün ortamlarda çalışmaktadır.

pip install tensorflow ile cihaza indirilip import tensorflow as tf ile kütüphane tanımlandıktan sonra artık kütüphane kullanılabilir hale gelir.

keras: Keras, her tür derin öğrenme modelini tanımlamak ve eğitmek için kullanılan, Python için yazılmış bir derin öğrenme kütüphanesidir. Keras, Tensorflow ile birlikte çalışabilmektedir.


pip install keras ile cihaza indirilip from tensorflow import keras ile kütüphane tanımlandıktan sonra artık kütüphane kullanılabilir hale gelir.

5.2 Sonuç

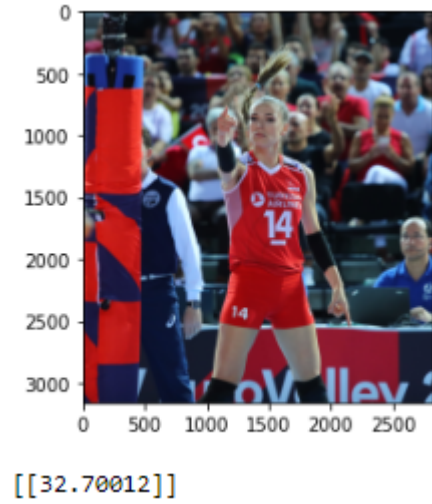

Test sonucunda CNN modeli ile yaş tahmini yapıldığında model, WIKI veri setinden oluşturulan test kümesi üzerinde %10'luk bir hata payı ile karşılaştı.

Sistem kişilerin yaşını tahmin ederken 20-50 yaş aralığında maximum doğruluk seviyesine ulaşmaktadır. Ayrıca kullanılan görüntünün kalitesi tahmini etkilemektedir.

Eğitimde verilen döngü değerlerine göre; düşük bir döngü değeri ile yüksek yaştaki insanların yaş tahmininde sistem iyi sonuç verirken yüksek bir döngü değeri ile küçük yaştaki insanların yaş tahmininde sistemin daha iyi bir sonuç verdiği gözlemlenmiştir.



Yukarıda yer alan fotoğrafta kişi 5 yaşındadır. Yüksek bir döngü değeri ile program +1.9 hatalı bir tahmin değeri ile sonuçlamıştır.



Yukarıda yer alan örneklerde Mustafa Kemal Atatürk'ün 1914 yılında, Eda Erdem Dünder'ın 2019 yılında çekilmiş fotoğrafları kullanılarak yaş tahmini yapılmıştır.

5.3 Hata Yüzdesi

İmkanlar dahilinde toplanan 30 veri yardımı ile elde edilen özgün bir veri kümesi üzerinde CNN modelinin hata yüzdesi araştırıldı. 6 ayrı kişiden, kişilerin izni ile 5'er adet farklı zamanlarda farklı yaşlarda çekilmiş fotoğraflar talep edildi. Fotoğraflar tek tek sistemde çalıştırıldı

ve sonuçlara göre hata yüzdesi için iki farklı yöntem denendi.

İlk olarak hata denince akla ilk gelen L_1 Hata Formülü;

$$L_1 = \frac{\sum_{i=1}^n |f_i - f(x_i)|}{\sum_{i=1}^n |f(x_i)|} \cdot 100$$

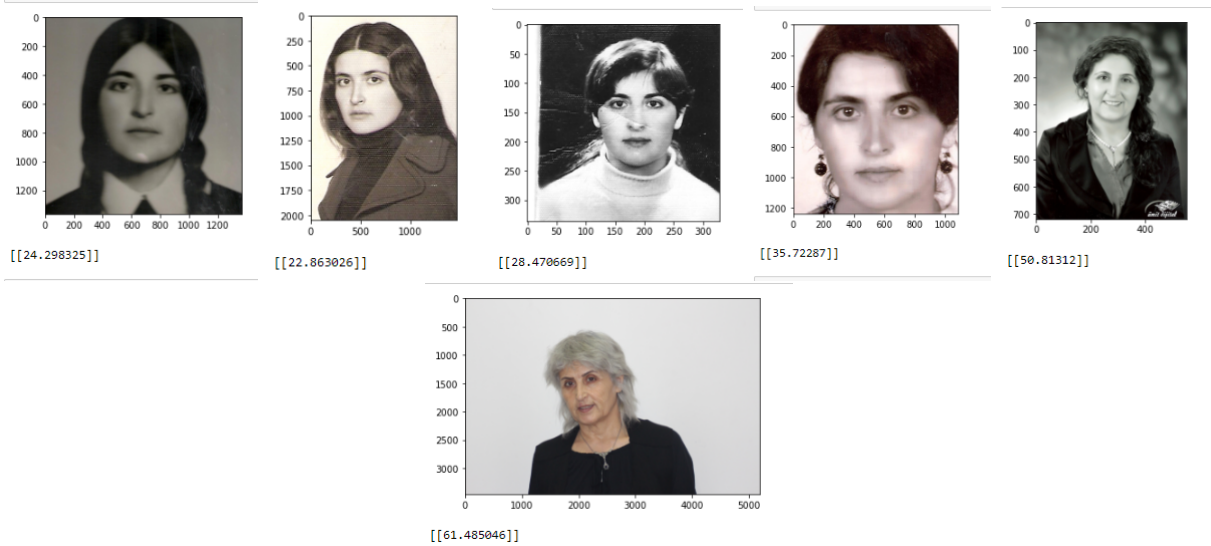
$n = 30$

f_i = Her bir veri için tahmin edilen yaş değeri

$f(x_i)$ = Her bir veri için gerçek yaş değeri

kullanılarak %17.5'luk bir hata ile karşılaşılmıştır.

İkinci yöntem olarak da yapılan tahminler sonucunda bir sapma miktarı belirlendi. Eğer tahmin bu sapma miktarı içindeyse 1 yani doğru fakat değilse 0 yani yanlış olarak tablolandı. +/-4 yıllık bir sapma miktarı belirlendiğinde %20 'lik bir hata ile karşılaşılrken; +/-6 lık bir sapma değerinde %20 'lik bir hata ile karşılaşılmıştır.



Yukarıda bazı tahmin örnekleri gösterilmiştir. Farklı zamanlarda, farklı yaşlarda çekilen aynı kişinin fotoğraflarından çıkan tahminler fotoğrafın sol altında yer almaktadır. (Kişiden fotoğraflarını yalnızca bu projede kullanmak üzere izin alınmıştır.) Sırası ile 20, 22, 28, 34, 51 ve 64 yaşlarda çekilmiş fotoğraflar tahmin edilmiştir.

Oluşturulan Python kodları <https://github.com/busrakocyigit> linkinde verilmiştir.

6 DeepFace

Tüm bu işlemler henüz tazeliğini koruyan DeepFace hazır paketi ile çok daha kısa bir işlemle yapılabilmektedir.

6.1 Deepface Nedir?

DeepFace, Python için bir yüz tanıma sistemi olarak 2015 yılında kurulmuş bir kitaplıktır. MIT Lisansı altında lisanslanmış açık kaynaklı bir proje olan DeepFace, Facebook'un yapay zeka araştırma ekibinden bir grup bilim insanı tarafından üretilmiştir. Facebook, DeepFace'in kullanımını ve yazılımını sürekli olarak genişletmiştir. Facebook kullanıcıları tarafından yüklenen yaklaşık 4 milyon görüntü üzerinde eğitilmiştir. Facebook Araştırma Ekibi, DeepFace yönteminin, insanların %97,53'e sahip olduğu Labeled Faces in the Wild (LFW) veri setinde %97,35 \pm %0,25 doğruluk oranına ulaştığını belirtti. Bu, DeepFace'in bazen insanlardan daha başarılı olduğu anlamına gelmektedir.



Şekil 5: DeepFace Logosu

6.2 DeepFace Nasıl Kullanılır?

DeepFace Python için yazılmış açık kaynaklı bir kütüphane olduğundan dolayı geliştiricileri tarafından kitaplığın hem özel hem de ticari bağlamda kullanmasına, değiştirmesine ve dağıtmasına izin verilmiştir.

Deepface kitaplığı ayrıca Python programlama dili için bir yazılım deposu olan Python Paket Dizini'nde (PyPI) yayınlanmıştır. DeepFace, TensorFlow ve Keras tarafından desteklenmiştir.

DeepFace paketi kurulup (`pip install deepface`) kitaplık içe aktarıldıktan sonra (`from deepface import DeepFace`) artık DeepFace kütüphanesi kullanılabilir hale gelir.

6.3 DeepFace Yüz Tanıma Modelleri

Alternatif yüz tanıma kütüphanelerinin geneli tek bir AI modeline hizmet ederken , DeepFace kütüphanesi birçok son teknoloji yüz tanıma modelini kapsamaktadır.

Yüz tanıma modelleri düzenli evrimsel sinir ağlarıdır ve yüzleri vektörler olarak temsil etmekten sorumludurlar. Aynı kişinin yüz çiftinin, farklı kişilerin yüz çiftinden daha benzer

olması beklenir.

Benzerlik, Kosinüs Benzerliği , Öklid Uzaklığı ve L2 formu gibi farklı metriklerle hesaplanabilir . Varsayılan yapılandırma kosinüs benzerliğini kullanır.

VGG-Face, *Facenet*, *OpenFace*, *DeepFace*, *DeepID*, *Dlib*, *ArcFace* derin öğrenme yüz tanıma algoritmaları DeepFace kütüphanesi ile kullanılabilir. Çoğu, son teknoloji Evrişimli Sinir Ağlarına (CNN) dayanır ve sınıfının en iyisi sonuçları sağlar. Bahsedilen modeller, deneyler sonucu insanların Wild veri kümesindeki Labeled Faces'te yüz tanıma için %97,53'lük bir puan elde ettiğini göstermiştir. İlginç bir şekilde, VGG-Face, FaceNet, Dlib ve ArcFace bu puanı çoktan geçmişken (insan performansından daha iyi performans gösteren AI algoritmaları) OpenFace, DeepFace ve DeepID, insan performansına çok yakın bir puan gösteriyor.

6.4 DeepFace'da Yüz Tanıma Analizi Nasıl Yapılır?

DeepFace kitaplığı, yüz tanıma için tüm önde gelen AI modellerini içerir ve arka planda tüm yüz tanıma prosedürlerini direkt olarak işler.

DeepFace sadece birkaç satır kodla çalıştırılabilir de, arkasında derinlemesine bir işlem döner. Sistemi çalıştırmak için kitaplığı içe aktarılıp ve tam görüntü yolunu girdi olarak iletmek yeterlidir.

DeepFace ile yüz tanıma çalıştırılmasında aşağıdaki özelliklere ulaşılabilir:

6.4.1 Yüz Doğrulama

Yüz doğrulama görevi, bir yüzün uyuşup uyuşmadığını doğrulamak için bir yüzü diğeriyle karşılaştırmayı ifade eder. Bu özellik fiziksel bir yüzün bir kimlik belgesindeki yüzle eşleştirmesini doğrulamak için kullanılabilir.

DeepFace'te Derin Öğrenme ile Yüz Doğrulamayı Çalıştırmak İçin; *DeepFace.verify()* girdisini çalıştırmak yeterlidir.

6.4.2 Yüz Tanıma

Görev, bir görüntü veri tabanında bir yüz bulmayı ifade eder. Yüz tanımanın gerçekleştirilmesi, yüz doğrulamanın birçok kez çalıştırılmasını gerektirir.

DeepFace'te Derin Öğrenme ile Yüz Nitelik Analizini Çalıştırmak İçin; *DeepFace.find()* girdisini çalıştırmak yeterlidir.

6.4.3 Yüz Öznitelik Analizi

Yüz öznitelik analizinin görevi, yüz görüntülerinin görsel özelliklerini tanımlamayı ifade eder. Buna göre, yüz özellikleri analizi, yaş, cinsiyet sınıflandırması, duygu analizi veya ırk/etnik köken tahmini gibi nitelikleri çıkarmak için kullanılır.

DeepFace'te Derin Öğrenme ile Yüz Nitelik Analizini Çalıştırmak İçin; *DeepFace.analyze()* girdisini çalıştırmak yeterlidir.

6.4.4 Gerçek Zamanlı Yüz Analizi

Bu özellik, web kameradan gerçek zamanlı video beslemesiyle yüz tanıma ve yüz öznitelik analizinin test edilmesini içerir.

DeepFace'te Derin Öğrenme ile Yüz Nitelik Analizini Çalıştırmak İçin; *DeepFace.stream()* girdisini çalıştırmak yeterlidir.

6.5 Yüz Dedektörleri:

Yüz tanımda hizalama, bir yüz tanıma hattı için çok önemli bir işlemdir. Google, yüz hizalamanın tek başına yüz tanıma doğruluk puanını %0,76 artırdığını belirtmiştir.

Yüz tanıma modelleri aslında CNN modelleridir ve standart boyutlu girdiler beklerler, temsilden önce yeniden boyutlandırma gereklidir. Deformasyonu önlemek için derin yüz, algılama ve hizalamadan sonra hedef boyut argümanına göre siyah dolgu pikselleri ekler.

DeepFace şu anda son teknoloji çok sayıda yüz hizalama yöntemini kullanmaktadır. En popüler yüz tanıma modelleri *OpenCV*, *MTCNN*, *RetinaFace*, *Mediapipe*, *Dlib*, *SSD*'dir. Uygulama yüksek güven gerektiriyorsa, *RetinaFace* veya *MTCNN* kullanılması önerilirken proje için yüksek hız daha önemliyse, *OpenCV* veya *SSD* kullanılması önerilmektedir. Bu projede *OpenCV* varsayılan dedektördür.



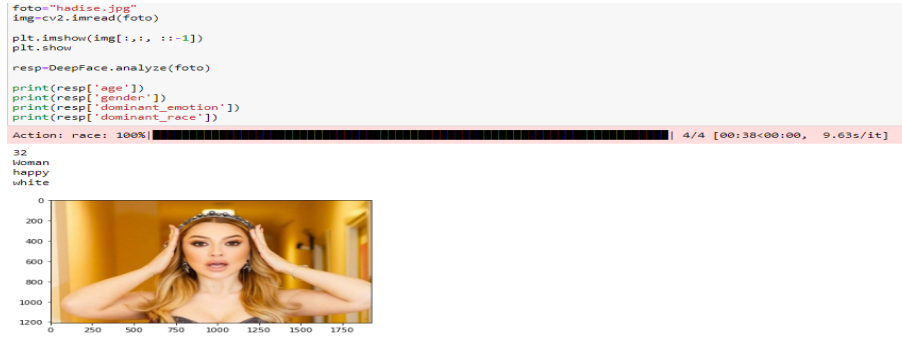
Şekil 6: DeepFace Yüz Dedektörleri

Kaynak: viso.ai

6.6 Yüz Öznitelik Analizi

DeepFace, yaş, cinsiyet, duygu ve ırk/etnik köken tahmini için güçlü bir yüz özniteliği analiz modülü ile birlikte gelir. DeepFace'in yüz tanıma modülü, mevcut son teknoloji modelleri sararken, yüz öznitelik analizinin kendi modelleri vardır. Şu anda, yaş tahmin modeli $\pm 4,6$ yıllık bir ortalama mutlak hataya ve cinsiyet tahmin modeli sosyal medya kaynaklı büyük veri setlerinin kullanılmasıyla %97'lik bir doğruluğa ulaşmıştır.

Bu projenin amacı yaş tahmini olduğundan dolayı bu *Derin Öğrenme ile Fotoğraflardan Yaş Tahmini* çalışmasında DeepFace hazır paketinin yüz öznitelik analiz fonksiyonundan yardım alınmıştır. Projenin amacı yaş tahmini olduğundan ötürü yüz tanıma analizinin yaş tahmini dışında sunulan tahminleri ihmal edilmiştir. Aşağıda bir kaç örnek eklenmiştir:

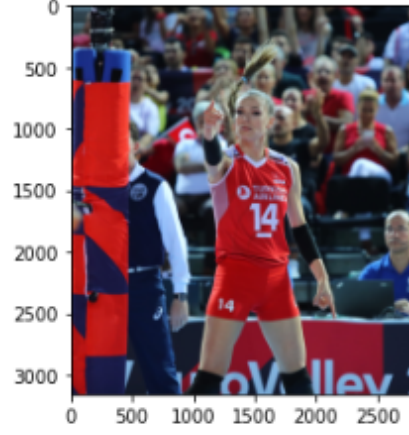


Şekil 7: DeepFace Yüz Öznitelik Analizi çalıştırılması

27



31



Yukarıdaki örneklerde Mustafa Kemal Atatürk'ün 1914 yılında, Hadise'nin 2018 yılında ve Eda Erdem Dünder'in 2019 yılında çekilmiş fotoğrafları kullanılarak yaş tahmini yapılmıştır.

6.7 Sonuç

Yapılan deneyler sonucunda DeepFace kütüphanesi yardımı ile yaş tahmini yapıldığında sistemin 20-40 yaş aralığında daha yakın sonuçlar verdiği gözlemlenmiştir. Ayrıca görüntü kalitesi arttıkça sonuç daha da olumlu hale geldiği gözlemlenmiştir.

6.8 Hata Yüzdesi

İmkanlar dahilinde toplanan 30 veri yardımı ile elde edilen özgün veri seti üzerinde DeepFace hazır paketinin hata yüzdesi araştırıldı. 6 ayrı kişiden, kişilerin izni ile 5'er adet farklı zamanlarda farklı yaşlarda çekilmiş fotoğraflar talep edildi. Fotoğraflar tek tek sistemde çalıştırıldı ve sonuçlara göre hata yüzdesi için iki farklı yöntem denendi. İlk olarak hata denince akla ilk gelen L_1 Hata Formülü;

$$L_1 = \frac{\sum_{i=1}^n |f_i - f(x_i)|}{\sum_{i=1}^n |f(x_i)|} \cdot 100$$

$n = 30$

f_i = Her bir veri için tahmin edilen yaş değeri

$f(x_i)$ = Her bir veri için gerçek yaş değeri

kullanılarak %26.1'lik bir hata ile karşılaşılmıştır.

İkinci yöntem olarak da yapılan tahminler sonucunda bir sapma miktarı belirlendi. Eğer tahmin bu sapma miktarı içindeyse 1 yani doğru fakat değilse 0 yani yanlış olarak tablolandı. +/-4 yıllık bir sapma miktarı belirlendiğinde %66 'lık bir hata ile karşılaşılrken; +/-6 lık bir sapma değerinde %50 'lik bir hata ile karşılaşılmıştır.

6.9 Yorum

Toplanan veri seti sonucunda DeepFace hazır paketinde hata yüzdesinin CNN modeline de bakıldığında daha yüksek çıkma nedeni DeepFace kitaplığının genç yaş kitlede daha iyi çalıştığından kaynaklı olduğu söylenebilir. Belirtildiği üzere toplanan veride karışık yaş gruplarında insanların fotoğrafları yer almaktadır. Genç yaşta veriler olduğu gibi yaşlı ve çocuk fotoğrafları da yer almaktadır. Gelişmekte olan yeni bir paket için bu sonuçlar oldukça tat-

min edici durumdadır.

Elde edilen hata miktarı oluşturulan özgün veri seti içindir. Eğitim verisi arttırıldıkça iki modelin de hatası düşecektir.

Kaynaklar

- [1] <https://www.kaspersky.com.tr/resource-center/definitions/what-is-facial-recognition>
- [2] <https://tr.wikipedia.org/wiki/TensorFlow>
- [3] <https://tr.wikipedia.org/wiki/Keras>
- [4] <https://en.wikipedia.org/wiki/DeepFace>
- [5] <https://github.com/serengil/deepface>
- [6] <https://data.vision.ee.ethz.ch/cvl/rrothe/imdb-wiki/>
- [7] Adrian Kjærran, Erling Stray Bugge, Christian Bakke Vennerød (2021) Facial Age Estimation Using Convolutional Neural Network
- [8] <https://github.com/ShreyanshJoshi/Facial-Demographics-using-CNN/blob/master/Age%20Estimation.ipynb>
- [9] <https://github.com/serengil/tensorflow>
- [10] <https://viso.ai/computer-vision/deepface/>
- [11] <https://github.com/serengil>
- [12] <https://medium.com/@rabiaokumus96/convolutional-neural-networks-evri%C5%9Fimsel-sinir-a%C4%9Flar%C4%B1-cceb887a2979>